消费信贷分群复核与客户支持试点建议

1. 给研究负责人的结论

现有材料可支持样本内分群标签重算、置信度敏感性及群体研究方案；不足以直接按发布的逾期账户数投放债务支持，也不足以作个人信用或授信决策。建议先通过分群口径的技术复核，再补齐债务变量编码，后者为试点实施前置依赖。

采用同一 Harvard Dataverse 资料页 6RK7RD 的原始调查、变量字典及三页问卷。主数据 1000 条、163 列、匿名 ID 唯一。原扩展名.tab 的两份文件实际是 CSV；原件没有改名或改写。

2. 分群结果与阈值

三列概率的和及取值已复核，最大概率类别与发布 cluster 逐条一致，字典所定义的 70%纯类/mixed 也逐条一致。最大类人数为 c1=186、c2=396、c3=418。这是发布数据内部一致性，不是模型对外部真实行为的预测正确率。

70%阈值下 c1=171、c2=347、c3=337、mixed=145；80%下分别 152、304、290、254。109 条从原纯类转为 mixed，其中 c1 为 19、c2 为 43、c3 为 47。不能只看纯类内部的构成变化，忽略被移出的 109 条。

60%下 mixed 为 64，90%下 mixed 为 388。最大两类概率差小于 0.1 的有 32 条，说明一部分标签归属较不稳定。60%、80%、90%及 0.1 间隔为作者敏感性，70%才是字典原定义；比较前不任意四舍五入概率。

3. 债务与营销指标为什么需要隔离

发布活动债务数与保留的 P21 代码 1 数量有 168 条不同，有无二元关系也有 13 条不同。发布值大于 0 为 669 人，P21 存在代码 1 为 656 人。缺少完整编码与派生脚本时，不能擅自把任一口径宣布为真实债务数。

发布 n_contas_atraso 在全部 1000 行都等于 P39 全部 15 列勾选数。有 P39 回答为 669 人，全空为 331 人；发布的该数大于 0 也为 669 人。问卷明确包括不知道、没有等特殊选项，故勾选数不等于真实逾期账户数。当前字典对 P39 列的说明截断，没有逐项完整标签，不能根据列序猜测并删除最后两列后宣布完成修复。

P29 及 P33 等问题存在跳题；P39—42 题块的非回答也需要区分条件资格与实际作答。问卷不能机械替代实际导出编码。P39 空白不直接填为明确无逾期；特殊选项也不视作一项违约。

六类渠道的发布报价数求和与 n_propostas_total 逐条一致，说明该指标能做内部算术描述。但收到报价既不是实际借款，也不是贷款转化率或逾期原因，不据此作因果推断。

4. 样本画像及其限度

按最大类统计，c1 有 186 条，发布活动债务数大于 0 的 170 条，收到报价 137 条；c2 分别 396、300、320；c3 分别 418、199、272。债务数字带上述待核口径，仅作发布字段描述，不能推成经验证的债务压力排序。

这批数据来自针对巴西中低社会经济阶层且可接入互联网人群的 2025 调查，元数据说明采用加权，但附件没有提供个人权重字段。本成果仅报样本未加权计数与比例，不假装再现加权总体估计，也不将元数据的总体误差说明移用于各小组。

类别名称是研究者潜在类别标签，不是人格结论、偿还能力或逾期概率。置信度上升意味着归属判断更明确，不意味着信用更好；只比较高置信度样本也可能改变构成。

5. 建议的研究试点与决策依赖

第一阶段可在内部使用样本复核分群与信息呈现：保留 70%原分层及 mixed，另给 80%敏感性。mixed 作为研究中需进一步澄清信息的层保留，不为整齐而删除。此处不认定匿名 ID 就是本机构客户或可实际联系的人。

债务支持试点应先取得完整 P21/P39 选项编码、实际实施版问卷、清洗/派生脚本和权重说明，再决定需求分层。禁止依现有派生逾期数宣称已识别所有逾期客户。

在有真实样本框、同意、预算和执行能力后，事前确定试点评价：成本与还款信息理解度、求助路径识别、参与/退出及缺失记录。实验分配、样本量、每层名额和改善率没有给定，均不填造；不声称已经实施随机实验或取得效果。

6. 来源与当前验证状态

资料页 doi:10.7910/DVN/6RK7RD 由用户指定 Harvard 目录中的数据集发现。官方目录、PDF 及原始字典取得成功；主数据网络刷新发生 IncompleteRead，使用未经改写的用户目录原件，并与当前官方目录原始 MD5 核验一致。原始格式 CSV 与默认 TSV 转换是两种表示，未把它们的哈希差异当作造假，也未冒称刷新成功。

本成果由 AI 直接构题和编写参考程序；来源回执、程序及实际执行时长另存。未运行独立解题 rollout、专家验收或难度校准，不能把本程序的短运行时间视为题目解题耗时。